Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa

Mestrado em Administração Pública – Ciência de Dados e Inteligência Artificial

Turma: 2005.2

Disciplina: Inteligência Artificial Generativa

Professor: Marcelo Pita

Alunos: Analécia Rorato; Fabricio Fernandes Santana; Paulo Ceser Siqueira Neves

Chatbot legislativo com RAG para respostas auditáveis sobre discursos da 56ª Legislatura do Senado Federal

Repositório: https://github.com/fabriciosantana/mcdia/tree/main/05-iag/4-project

Resumo

Este trabalho investiga a aplicação de *retrieval-augmented generation* (RAG) no desenvolvimento de um *chatbot* legislativo para consulta a discursos da 56ª Legislatura do Senado Federal (2019–2023). Parte-se da dificuldade de recuperar informações parlamentares por meio de linguagem natural com precisão factual, contextualização e rastreabilidade. A metodologia consistiu na construção de um *pipeline* com preparação de dados, segmentação textual, enriquecimento por metadados, geração de *embeddings*, indexação vetorial e fluxo de consulta baseado em LLM. A solução foi implementada em ambiente reprodutível, com *scripts* próprios para ingestão e avaliação, e validada por três estudos de caso manuais, três rodadas automatizadas com rubrica e LLM como juiz, além de revisão humana amostral das respostas automatizadas. Os resultados indicam bom desempenho em perguntas factuais, temáticas e de autoria bem delimitada, com médias entre 9,15 e 9,55 nas rodadas automatizadas. Observou-se maior instabilidade em consultas que exigem precisão numérica, comparação entre autores, controle de escopo ou síntese multifocal. Conclui-se que a abordagem é viável para recuperação auditável de discursos legislativos, desde que acompanhada de governança de fontes, avaliação sistemática e supervisão humana.

Palavras-chave: RAG; inteligência artificial; *chatbot* legislativo; recuperação de informação; Senado Federal; LLM.

1 Introdução

1.1 Contextualização

O avanço recente dos grandes modelos de linguagem (*large language models* – LLMs) ampliou significativamente o interesse por soluções capazes de responder perguntas em linguagem natural (MINAEE et al., 2024). No setor público, esse interesse é particularmente relevante diante de acervos extensos, dinâmicos e heterogêneos, tais como legislação, pareceres, notas técnicas, discursos parlamentares e documentos administrativos (INTER-PARLIAMENTARY UNION, 2024). Nesses ambientes, o desafio não se restringe ao armazenamento da informação, mas

abrange, sobretudo, sua recuperação qualificada, contextualizada e verificável (WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023).

Apesar de seu potencial, o uso direto de LLMs apresenta limitações amplamente discutidas na literatura, entre as quais se destacam a alucinação, a dependência do conhecimento incorporado aos dados de treinamento e a dificuldade de identificar as evidências utilizadas na produção das respostas (GAO et al., 2023). Tais limitações assumem maior gravidade em contextos institucionais nos quais se exigem transparência, verificabilidade, controle das fontes e responsabilização pelos conteúdos produzidos (WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023).

Nesse cenário, a abordagem *retrieval-augmented generation* (RAG) apresenta-se como alternativa tecnicamente promissora, pois, em vez de depender exclusivamente do conhecimento internalizado no modelo, sistemas RAG recuperam trechos relevantes de uma base documental externa e os incorporam ao contexto da geração (GAO et al., 2023). Com isso, a abordagem pode elevar a precisão factual e a atualidade das respostas, ao mesmo tempo em que favorece a explicitação das fontes que as sustentam (GAO et al., 2023).

No contexto do Parlamento brasileiro, a organização do conhecimento legislativo e a ampliação do acesso qualificado à informação constituem desafios relevantes de pesquisa aplicada. Como observam Martellote Viola et al. (2025), o emprego de inteligência artificial nesse domínio deve ser acompanhado de atenção à estrutura informacional, à mediação documental e à explicabilidade dos resultados.

Com base nessas questões, o presente trabalho propõe o desenvolvimento de um *chatbot* legislativo baseado em RAG, voltado à consulta de discursos da 56ª Legislatura do Senado Federal.

1.2 Motivação

A administração pública contemporânea opera sob crescente pressão por transparência, rastreabilidade, eficiência e capacidade de resposta (UNITED NATIONS, 2015). No ambiente parlamentar, a consulta a discursos e pronunciamentos mostra-se relevante para diversas finalidades, tais como análise temática, comparação de posicionamentos, apoio técnico a gabinetes, elaboração de relatórios, produção de subsídios e atendimento ao cidadão (SKUBIC; FIŠER, 2024). Estudos recentes da Consultoria Legislativa do Senado mostram, além disso, que os pronunciamentos em plenário entre 2007 e 2024 apresentam transformações relevantes em volume, extensão, interatividade e complexidade textual, reforçando a pertinência de tratá-los como corpus dinâmico de pesquisa institucional (BLANCO, 2025, 2026). Entretanto, a simples disponibilização pública desses documentos não garante, por si só, acesso eficiente à informação que eles contêm (GEUNIS, 2023).

Em grandes acervos discursivos, mecanismos tradicionais de busca, predominantemente baseados em correspondência lexical, tendem a ser insuficientes quando o usuário formula perguntas complexas, comparativas, interpretativas ou orientadas à síntese (GUPTA et al., 2024). Além disso, em bases documentais extensas, a recuperação da informação frequentemente depende de conhecimento prévio sobre vocabulário, datas, autores ou sobre a própria organização do acervo, o que dificulta o acesso substantivo à informação mesmo quando ela está formalmente disponível (BANDEIRA; BERNARDES, 2016; GEUNIS, 2023). Como consequência, a informação permanece formalmente acessível, mas substantivamente difícil de explorar (BANDEIRA;

BERNARDES, 2016; GEUNIS, 2023).

Paralelamente, soluções baseadas exclusivamente em LLMs generalistas podem produzir respostas plausíveis e linguisticamente bem estruturadas, porém desprovidas de fundamentação verificável (ANH-HOANG et al., 2025; GAO et al., 2023). Em domínios institucionais, tal comportamento é particularmente problemático, pois compromete a confiança, a responsabilização e o uso controlado da tecnologia (ALMEIDA; SANTOS JÚNIOR, 2025; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023). A literatura de RAG indica que parte desses riscos pode ser mitigada ao ancorar a geração em documentos externos, controláveis e atualizáveis, desde que isso seja combinado a práticas de avaliação, versionamento, rastreabilidade e monitoramento contínuo (GAO et al., 2023; SAAD-FALCON et al., 2024; ES et al., 2023).

Dessa forma, este trabalho é motivado pela necessidade de investigar uma solução tecnicamente viável e institucionalmente adequada para ampliar o acesso qualificado a discursos parlamentares, combinando busca semântica, geração textual e verificação documental.

1.3 Problema de pesquisa

Diante desse quadro, formula-se o seguinte problema de pesquisa: como obter, por meio de consultas em linguagem natural aos discursos da 56ª Legislatura do Senado Federal, respostas úteis, fundamentadas em evidências recuperadas e compatíveis com exigências de verificação institucional?

Esse problema de pesquisa decorre da constatação de que o acesso documental, embora formalmente assegurado, ainda enfrenta limitações relevantes quando se exigem recuperação semântica, síntese orientada ao usuário e indicação clara das fontes utilizadas na resposta (BANDEIRA; BERNARDES, 2016; GEUNIS, 2023; GAO et al., 2023).

1.4 Objetivos

O objetivo geral deste trabalho é desenvolver e demonstrar uma prova de conceito reprodutível de *chatbot* legislativo baseada em RAG para consulta a discursos parlamentares da 56ª Legislatura do Senado Federal, com foco na produção de respostas fundamentadas em evidências recuperadas e compatíveis com exigências de verificação institucional.

Como objetivos específicos, definem-se:

1. estruturar uma base de conhecimento consultável a partir dos discursos parlamentares;
2. possibilitar a formulação de perguntas em linguagem natural com respostas fundamentadas em trechos recuperados;
3. avaliar empiricamente a qualidade inicial da recuperação e das respostas geradas;
4. documentar uma arquitetura reprodutível, modular e passível de evolução para cenários institucionais.

1.5 Justificativa

A relevância deste estudo decorre de sua contribuição em dois planos complementares. No plano prático, a pesquisa investiga uma forma de ampliar o acesso qualificado a informações parla-

mentares públicas, com potencial para fortalecer transparência, memória institucional e apoio a atividades de gabinete, pesquisa e controle social (INTER-PARLIAMENTARY UNION, 2024; GEUNIS, 2023). No plano metodológico e aplicado, o trabalho examina a aplicação de técnicas contemporâneas de recuperação e geração em um domínio documental complexo, marcado por exigências elevadas de explicabilidade, confiabilidade e vinculação às fontes (MARTELLOTE VIOLA et al., 2025; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023).

Além disso, o estudo se justifica pela aderência do problema a desafios concretos da administração pública digital. Em vez de tratar a inteligência artificial como mecanismo autônomo de produção de respostas, propõe-se uma abordagem em que a geração textual é condicionada por fontes documentais públicas, controláveis e auditáveis. Essa orientação é coerente com demandas institucionais por uso responsável da IA em contextos sensíveis (ALMEIDA; SANTOS JÚNIOR, 2025; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023).

2 Fundamentação teórica

2.1 Arquiteturas de LLM relacionadas ao problema

Os componentes mais diretamente relacionados a este trabalho são, de um lado, os LLMs generativos baseados em transformers (VASWANI et al., 2017) e, de outro, os modelos de embeddings utilizados para recuperação semântica (NIE et al., 2024). Enquanto o LLM atua como componente de síntese textual, os embeddings convertem documentos e consultas em vetores, permitindo o cálculo de similaridade semântica em bancos vetoriais (GAO et al., 2023).

Em sistemas RAG, esses componentes operam de maneira complementar: o modelo de embedding sustenta a recuperação, enquanto o modelo generativo formula a resposta a partir do contexto recuperado (GAO et al., 2023). Essa separação favorece uma arquitetura modular, a especialização de componentes e a evolução incremental da solução (GAO et al., 2024).

Segundo Gao et al. (2023), sistemas RAG podem ser classificados em abordagens ingênuas, avançadas e modulares. Para o problema investigado, a arquitetura modular mostra-se adequada por permitir substituir, de forma independente, extratores documentais, estratégias de segmentação, modelos de embedding, bancos vetoriais, reranqueadores e modelos gerativos. Em contextos institucionais, essa característica é desejável porque infraestrutura, custos, segurança e políticas internas podem exigir alterações graduais da pilha tecnológica.

Essa modularidade, contudo, não deve ser interpretada como garantia automática de qualidade. A literatura apresenta o RAG como estratégia para reduzir problemas de desatualização, baixa verificabilidade e alucinação, mas não como solução suficiente para eliminá-los. O desempenho final continua dependente da qualidade documental, da segmentação, da recuperação, do desenho do prompt, da seleção de contexto e dos mecanismos de avaliação adotados (GAO et al., 2023; GUPTA et al., 2024; SAAD-FALCON et al., 2024). Essa leitura é importante em aplicações públicas, nas quais uma resposta plausível, mas mal fundamentada, pode comprometer confiança institucional.

2.2 Técnicas relacionadas

As principais técnicas relacionadas ao *pipeline* deste projeto incluem extração documental, *chunking*, geração de *embeddings* semânticos, recuperação vetorial, seleção contextual e *prompting* orientado a evidências, podendo também envolver etapas de reranqueamento em arquiteturas RAG (GAO et al., 2023; MAHARJAN; YADAV, 2026; WANG et al., 2025). Em conjunto, essas técnicas convertem o acervo em unidades recuperáveis, identificam trechos semanticamente relevantes e delimitam o contexto encaminhado ao modelo generativo. O *prompting* orientado a evidências complementa esse fluxo ao instruir o modelo a privilegiar o contexto recuperado, evitar inferências especulativas e explicitar referências verificáveis.

Dentre essas técnicas, o *chunking* ocupa posição central. Estudos recentes sobre segmentação documental em RAG indicam que escolhas inadequadas de divisão podem comprometer a recuperação semântica, seja por fragmentarem indevidamente o contexto, seja por gerarem blocos excessivamente extensos, com perda de precisão na busca (WANG et al., 2025; BHAT et al., 2025). No presente projeto, a segmentação documental exigiu sucessivos ajustes empíricos para equilibrar granularidade semântica, preservação de contexto e restrições operacionais da base vetorial e do processo de ingestão. Assim, a experiência prática corrobora a literatura ao indicar que o *chunking* não constitui etapa meramente operacional, mas um dos principais determinantes do desempenho de um sistema RAG.

Surveys e *frameworks* recentes também indicam que, em ambientes reais, a qualidade de sistemas RAG depende de mecanismos de avaliação, rastreabilidade e comparação entre configurações, não apenas do *pipeline* básico de recuperação e geração (GAO et al., 2023; SAAD-FALCON et al., 2024; ES et al., 2023). Essa perspectiva orientou a criação de *scripts* próprios de preparação, importação, avaliação e documentação da configuração experimental.

No campo da avaliação, estratégias baseadas em LLM como juiz têm sido utilizadas para escalar a análise de respostas geradas, sobretudo quando combinadas com rubricas explícitas (LIU, Y. et al., 2023; LIU, S. et al., 2025). Ainda assim, o julgamento automatizado pode variar conforme o modelo avaliador adotado, a rubrica utilizada e o grau de abertura da tarefa; por isso, em aplicações RAG, tende a ser mais robusto quando tratado como instrumento auxiliar, combinado a evidências qualitativas, validação humana e análise das fontes recuperadas (LIU, S. et al., 2025; LIU, Y. et al., 2023; SAAD-FALCON et al., 2024; ES et al., 2023).

2.3 Trabalhos e soluções relacionadas

Gao et al. (2023) oferecem uma base conceitual abrangente para compreender o RAG como resposta aos problemas de desatualização, baixa verificabilidade e geração não rastreável em LLMs, além de orientar a decomposição do problema em etapas de recuperação, aumento de contexto e geração. No plano arquitetural, Gupta et al. (2024) consolidam o estado da arte em RAG ao discutir como mecanismos de recuperação e geração se combinam para mitigar limitações de LLMs e ao destacar desafios de precisão, fidelidade e coordenação entre componentes.

Os trabalhos de Minaee et al. (2024) e Vaswani et al. (2017) oferecem o pano de fundo técnico para o uso de LLMs generativos neste projeto: o primeiro sintetiza a evolução recente e as capacidades desses modelos em ampla gama de tarefas, enquanto o segundo estabelece a base arquitetural dos transformers. Nie et al. (2024) complementam esse quadro ao tratar os

text embeddings como tecnologia fundacional para tarefas de busca semântica e recuperação de informação, enfatizando a relevância da integração entre LLMs e *embeddings* em aplicações contemporâneas.

A literatura recente sobre alucinação em LLMs evidencia que esses modelos podem produzir saídas fluentemente redigidas, porém factualmente incorretas ou não verificáveis, o que reforça, em contextos públicos sensíveis, a necessidade de soluções explicáveis e auditáveis, com mecanismos de fundamentação documental, governança e controle institucional (ANH-HOANG et al., 2025; GAO et al., 2023; ALMEIDA; SANTOS JÚNIOR, 2025).

Em termos de contexto institucional, United Nations (2015), Inter-Parliamentary Union (2024), Westminster Foundation for Democracy (2023) e Geunis (2023) indicam que parlamentos e administrações públicas operam sob pressões crescentes por transparência, responsividade, responsabilização e uso qualificado da informação. Nesse domínio, discursos e debates constituem insumos centrais para análise política e apoio técnico, mas os sítios parlamentares frequentemente funcionam mais como repositórios informacionais do que como instrumentos de exploração substantiva, tornando o acesso dependente de conhecimento prévio sobre estrutura e vocabulário (SKUBIC; FIŠER, 2024; BANDEIRA; BERNARDES, 2016).

No caso brasileiro, os Textos para Discussão da Consultoria Legislativa do Senado oferecem evidência empírica recente sobre a relevância e a complexidade do acervo de pronunciamentos. Blanco (2025) analisa discursos em plenário entre 2007 e 2024 e identifica mudanças de volume, extensão, tempo de fala e interatividade, associadas a transformações institucionais e tecnológicas. Em estudo complementar, Blanco (2026) examina leiturabilidade e traços morfossintáticos do mesmo domínio discursivo por meio de técnicas computacionais de análise textual. Esses trabalhos reforçam que os discursos do Senado constituem corpus relevante para métodos computacionais, embora se concentrem em análise descritiva e interpretativa, e não no desenvolvimento de uma camada interativa voltada à consulta, à recuperação semântica e à geração de respostas verificáveis.

No campo da governança pública de inteligência artificial, estudos e diretrizes institucionais enfatizam responsabilidade, transparência, monitoramento, gestão de riscos e alinhamento a finalidades públicas (ALMEIDA; SANTOS JÚNIOR, 2025; INTER-PARLIAMENTARY UNION, 2024; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023). Para aplicações RAG em acervos legislativos, esse conjunto de referências reforça a importância de bases documentais controladas, metadados preservados, respostas verificáveis e avaliação contínua.

No domínio político, Khaliq et al. (2024) demonstram que arquiteturas RAG podem apoiar tarefas de fact-checking político com raciocínio fundamentado em evidências externas, articulando recuperação rigorosa e geração apoiada em fontes verificáveis. Ainda que o objetivo deste trabalho não seja a verificação factual multimodal, a pesquisa desses autores é relevante por demonstrar a aderência do domínio político-parlamentar a abordagens baseadas em recuperação e geração com evidências.

Por fim, Martellote Viola et al. (2025) aproxima a discussão do contexto brasileiro ao tratar da inteligência artificial na organização do conhecimento legislativo. Sua contribuição reforça a pertinência de soluções explicáveis, documentalmente ancoradas e informacionalmente estruturadas em ambientes parlamentares, oferecendo referencial específico para a aplicação proposta

neste trabalho.

2.4 Síntese da revisão e lacuna de pesquisa

A revisão realizada permite identificar três conjuntos de literatura complementares. O primeiro, voltado a RAG, LLMs, *embeddings*, segmentação documental e avaliação automatizada, oferece a base técnica do trabalho (GAO et al., 2023; MINAEE et al., 2024; NIE et al., 2024; SAAD-FALCON et al., 2024). O segundo, dedicado a parlamentos, organização da informação legislativa e discurso parlamentar, delimita a relevância institucional do domínio (SKUBIC; FIŠER, 2024; MARTELLOTE VIOLA et al., 2025; INTER-PARLIAMENTARY UNION, 2024). O terceiro, mais diretamente ligado ao caso brasileiro, aplica métodos computacionais ao corpus de discursos do Senado, mas com foco predominante em análise descritiva, linguística ou discursiva (BLANCO, 2025, 2026).

A lacuna remanescente, portanto, não está na ausência de estudos sobre RAG nem na ausência de estudos sobre discursos parlamentares, mas na articulação aplicada entre esses dois campos. Embora a literatura indique o potencial do RAG para elevar a precisão factual e a verificabilidade de sistemas baseados em LLM, esse potencial depende de decisões metodológicas situadas, e não apenas da adoção abstrata da arquitetura (GAO et al., 2023; GUPTA et al., 2024; SAAD-FALCON et al., 2024). Parte significativa da literatura técnica permanece concentrada em discussões conceituais amplas, cenários corporativos ou aplicações em domínios distintos do acervo legislativo brasileiro (GAO et al., 2023; GUPTA et al., 2024). Ainda que pesquisas recentes já explorem computacionalmente discursos do Senado sob perspectivas quantitativas, discursivas e linguísticas, são menos frequentes estudos que articulem, em um mesmo desenho aplicado, corpus parlamentar nacional, preparação reprodutível de base documental, preservação de metadados legislativos, fluxo RAG operacional e avaliação empírica das respostas geradas (BLANCO, 2025, 2026; MARTELLOTE VIOLA et al., 2025).

Assim, identifica-se uma lacuna aplicada relacionada à construção, à documentação e à avaliação de soluções RAG voltadas especificamente à consulta de discursos parlamentares no contexto do Senado Federal. Este trabalho busca contribuir para seu preenchimento ao propor, implementar e avaliar uma prova de conceito reprodutível de *chatbot* legislativo baseada em RAG, com foco em discursos da 56ª Legislatura. A contribuição reside não apenas no protótipo, mas também na explicitação do *pipeline*, no enriquecimento dos *chunks* com metadados, na documentação dos artefatos de ingestão e avaliação e na combinação entre estudos de caso, rodadas automatizadas com rubrica e análise manual amostral.

3 Caracterização do problema

3.1 Problema da administração pública

O problema central abordado neste trabalho consiste na dificuldade de transformar grandes acervos de discursos legislativos em bases efetivamente consultáveis por meio de perguntas em linguagem natural, com respostas úteis, contextualizadas e verificáveis. Embora esses discursos sejam públicos, seu volume, diversidade temática, dispersão temporal e variação formal tornam a recuperação de argumentos, posicionamentos, temas recorrentes e referências históricas uma tarefa complexa quando realizada por meio de mecanismos tradicionais de busca (KAVČIČ et

al., 2024; BLANCO, 2025, 2026).

Na prática, esse quadro impacta diferentes atores institucionais. Gabinetes parlamentares podem precisar recuperar rapidamente posicionamentos anteriores sobre determinado tema; equipes técnicas precisam localizar subsídios para notas, relatórios e pareceres; pesquisadores e jornalistas demandam acesso qualificado a discursos para fins analíticos; e cidadãos interessados em transparência e controle social podem se beneficiar de instrumentos que tornem o acervo mais acessível e inteligível (BANDEIRA; BERNARDES, 2016). Na ausência de uma camada de recuperação semântica, o acesso ao conteúdo tende a ser fragmentado, lento e altamente dependente de conhecimento prévio sobre a estrutura documental e os termos empregados nos discursos (GAO et al., 2023; MARTELLOTE VIOLA et al., 2025; GEUNIS, 2023).

Desse modo, o *chatbot* legislativo com RAG proposto neste trabalho procura enfrentar essa lacuna ao acrescentar uma camada de mediação informacional que combina recuperação semântica, contextualização documental e geração textual ancorada em evidências.

3.2 Partes interessadas

As partes interessadas no projeto abrangem, em primeiro lugar, gabinetes parlamentares, consultorias legislativas e assessorias técnicas, que demandam acesso rápido e qualificado a discursos e posicionamentos anteriores. Também se incluem equipes de transparência, gestão da informação e tecnologia, para as quais são particularmente relevantes aspectos de governança, manutenção, rastreabilidade e evolução da solução.

Além disso, pesquisadores das áreas de ciência política, direito, administração pública e ciência da informação constituem público potencial do sistema, bem como cidadãos e organizações da sociedade civil interessados em controle social e acompanhamento da atividade parlamentar (MARTELLOTE VIOLA et al., 2025; GEUNIS, 2023).

3.3 Critérios de sucesso

Os critérios de sucesso definidos para este trabalho incluem os seguintes aspectos: a capacidade de indexar uma base representativa de discursos parlamentares; a recuperação de trechos relevantes para perguntas factuais e analíticas; a geração de respostas em português fundamentadas no contexto recuperado; a apresentação de referências e metadados associados aos discursos utilizados; a automatização das etapas de importação e avaliação; e a reprodutibilidade da solução.

Tais critérios dialogam com recomendações da literatura para sistemas RAG e avaliação automatizada, que enfatizam avaliação contínua, reprodutibilidade e rastreabilidade como propriedades desejáveis em soluções voltadas ao tratamento de informação institucionalmente relevante (GAO et al., 2023; SAAD-FALCON et al., 2024; ES et al., 2023).

4 Proposta de solução

4.1 Arquitetura do chatbot legislativo

A solução proposta concretiza-se em um *chatbot* legislativo que utiliza a abordagem RAG para responder a consultas sobre discursos da 56ª Legislatura do Senado Federal. A arquitetura

compreende cinco componentes articulados: uma instância do Open WebUI, utilizada como interface de interação e orquestração do fluxo RAG; *scripts* em Python empregados na extração, preparação, importação e avaliação do conteúdo documental; o ChromaDB, utilizado como banco vetorial acessado por HTTP; o Ollama, mantido como alternativa para integração com modelos locais; e a API da OpenAI, utilizada na configuração experimental validada para geração de *embeddings* e respostas.

A solução foi definida para operar localmente com uso de Docker e preparada para funcionar tanto com *embeddings* locais, via Ollama, quanto com *embeddings* providos por serviços externos, como a API da OpenAI. Na configuração experimental validada, adotou-se esta segunda opção. Essa flexibilidade amplia a adaptabilidade da solução a diferentes restrições institucionais de infraestrutura, custo ou política tecnológica.

4.2 Pipeline desenvolvido

O *pipeline* do projeto inicia-se com a aquisição dos dados, baseada no *dataset* utilizado no projeto[1], que reúne discursos da 56ª Legislatura do Senado Federal. Esse *dataset* foi construído em trabalho anterior a partir do portal de dados abertos do Senado. Na etapa de pré-processamento e seleção textual, priorizou-se o campo "TextoDiscursoIntegral", recorrendo-se aos campos "Resumo" e "Indexacao" quando necessário, de modo a privilegiar o conteúdo mais completo e informativo na construção da base.

Em seguida, realizou-se o *chunking*, com geração de segmentos enriquecidos por metadados relevantes[2]. Esses metadados incluem data, autor, partido, unidade da federação, tipo de uso da palavra, resumo, indexação e URL do texto integral. Tal modelagem favorece não apenas a recuperação semântica, mas também a verificação posterior das respostas, uma vez que permite reconstituir a origem documental dos trechos utilizados.

A partir desses segmentos, foram gerados lotes de ingestão para o Open WebUI em formato Markdown, além de um arquivo `jsonl` de referência[3]. A importação desses lotes foi automatizada por script responsável por realizar o upload, monitorar o processamento e viabilizar a inclusão dos conteúdos na *knowledge base* do Open WebUI. Concluída a ingestão, procedeu-se à indexação vetorial, com geração e persistência dos *embeddings* no ChromaDB.

Na etapa de consulta, o fluxo RAG opera com recuperação vetorial, montagem do contexto recuperado, aplicação do *prompt* operacional configurado no Open WebUI[4] e geração da resposta pelo modelo, com parte desses passos internalizada na própria plataforma. Por fim, a avaliação foi apoiada por automação em Python, que consulta a *knowledge base* via API e produz saídas nos formatos `.jsonl`, `.md` e `.csv`, viabilizando análise estruturada, avaliação por LLM como juiz, revisão qualitativa e comparação entre execuções.

4.3 Principais contribuições

O projeto apresenta contribuições em dois níveis complementares: técnico-metodológico e institucional. No plano técnico-metodológico, o trabalho constrói uma prova de conceito reprodutível

[1] *Dataset* público no Hugging Face.
[2] Metadados públicos da base construída.
[3] Arquivo público de chunks em JSONL.
[4] *Prompt* operacional público.

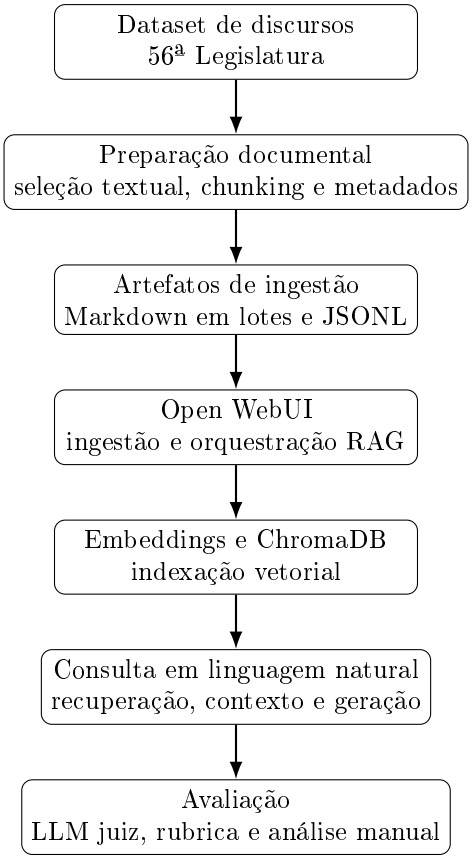


Figura 1: Fluxo geral da prova de conceito RAG para consulta a discursos legislativos

de *chatbot* legislativo com RAG, adaptada a um acervo real do Senado Federal. A contribuição não consiste em propor um *benchmark* definitivo para avaliação de RAG legislativo, mas em documentar um *pipeline* completo, com preparação da base, enriquecimento de *chunks* por metadados, ingestão, consulta, avaliação automatizada, análise qualitativa e discussão explícita dos limites observados. Nesse percurso, o estudo evidencia empiricamente a sensibilidade do desempenho à formulação das perguntas, ao controle de escopo, à escolha do LLM juiz e à configuração da recuperação semântica.

No plano institucional, a solução oferece evidência inicial de viabilidade para aplicar técnicas contemporâneas de recuperação e geração ao contexto do Parlamento brasileiro, aproximando recomendações gerais da literatura sobre RAG às condições de um acervo legislativo público já explorado por estudos computacionais recentes sobre discursos em plenário (BLANCO, 2025, 2026). Desse modo, o trabalho contribui para a discussão sobre uso responsável de inteligência artificial em contextos parlamentares e sobre formas de manter as respostas vinculadas a documentos verificáveis.

4.4 Riscos e limitações

Os principais riscos e limitações identificados relacionam-se à sensibilidade do desempenho à estratégia de *chunking*, à possibilidade de combinação excessiva de fontes em perguntas muito abertas, à dependência da qualidade dos documentos e metadados de origem, ao risco de respostas excessivamente amplas ou inferenciais e à variabilidade da avaliação por LLM como juiz.

Além disso, em cenários de restrição de recursos computacionais locais, a solução pode depender operacionalmente de serviços externos, tanto para geração de *embeddings* quanto para parte da geração de respostas.

Esses riscos devem ser compreendidos em perspectiva ampliada. A literatura sobre RAG e governança pública de IA indica que sistemas apoiados em recuperação documental podem melhorar o controle sobre fontes e contexto, mas não eliminam automaticamente problemas de qualidade documental, conformidade, monitoramento ou avaliação (GAO et al., 2023; ALMEIDA; SANTOS JÚNIOR, 2025; SAAD-FALCON et al., 2024). Em outras palavras, o RAG reduz determinadas fragilidades do uso isolado de LLMs, mas não substitui processos institucionais de revisão.

5 Experimentos e demonstração

5.1 Setup experimental

O experimento utilizou uma base derivada do *dataset* utilizado no projeto[5], contendo 15.729 registros do conjunto de origem, dos quais 15.726 correspondiam a discursos efetivamente escritos e 3 foram descartados por ausência do texto integral. A escolha desse corpus dialoga com estudos recentes que analisam computacionalmente discursos do Senado no período 2007–2024, mas recorta a 56ª Legislatura para construir e avaliar uma base RAG específica (BLANCO, 2025, 2026). A partir desses registros, foram gerados 23.806 *chunks*, organizados em 120 arquivos Markdown de ingestão. Esses números foram registrados nos artefatos públicos de construção da base[6], assegurando rastreabilidade quantitativa da base construída.

Na etapa de preparação da base, adotaram-se como parâmetros principais `max_words = 850`, `overlap_words = 150` e `chunks_per_file = 200`, buscando equilibrar granularidade e preservação de contexto. Além do texto segmentado, cada *chunk* foi enriquecido com metadados como data, autor, partido, unidade federativa, casa legislativa, tipo de uso da palavra, resumo, indexação e URL do discurso original, de modo a favorecer recuperação qualificada e verificação das respostas. Já na etapa posterior de ingestão no Open WebUI, os arquivos *Markdown* previamente segmentados foram processados com *Markdown Header Text Splitter* habilitado, *Chunk Size* = 6000, *Chunk Overlap* = 500 e *Chunk Min Size Target* = 2000, além do uso do modelo de embedding `text-embedding-3-small` e lote de *embeddings* de tamanho 32.

O *prompt* de RAG foi evoluído iterativamente para atender a requisitos centrais do problema institucional: privilegiar o contexto recuperado, proibir explicitamente a invenção de fatos, exigir declaração de insuficiência quando a informação solicitada não estivesse presente no contexto, distribuir citações ao longo da resposta e exigir uma seção final de referências com os metadados dos discursos utilizados. O *prompt* configurado no modelo RAG do Open WebUI está disponível no repositório do projeto[7] e foi utilizado tanto no uso interativo do sistema na própria plataforma quanto na bateria automatizada mais recente. Nas consultas automatizadas, o *script* enviou a pergunta do usuário e anexou a coleção indexada, deixando que o Open WebUI aplicasse o *template* RAG configurado no servidor e realizasse internamente a recuperação, a montagem do

[5] *Dataset* público no Hugging Face.
[6] Metadados de construção da base; arquivo JSONL de chunks.
[7] *Prompt* do fluxo RAG.

contexto e a formulação da resposta. Com isso, buscou-se aproximar a avaliação automatizada do fluxo de uso validado manualmente, preservando fidelidade ao contexto recuperado, controle de escopo, reconhecimento explícito de ambiguidade e estrutura de saída orientada à verificação das fontes. Tal configuração alinha-se à literatura que enfatiza verificabilidade, controle documental e avaliação explícita em sistemas RAG (GAO et al., 2023; SAAD-FALCON et al., 2024; ES et al., 2023).

Para a avaliação, desenvolveu-se um *script* em *Python* que automatizou consultas à *knowledge base* do Open WebUI via API, gerando saídas em `.jsonl`, `.md` e `.csv`. O script envia cada pergunta ao endpoint de chat da plataforma e anexa a coleção indexada como *file* do tipo `collection`; com isso, a recuperação e a montagem do contexto final ficam a cargo do próprio Open WebUI, e não de lógica externa implementada no *script*. Os artefatos preservam a pergunta, a resposta, as fontes recuperadas, a configuração da rodada, os identificadores da *knowledge base* e os *hashes* dos principais arquivos usados na preparação da base. A pontuação foi atribuída em uma segunda etapa de avaliação por LLM como juiz, segundo a estratégia de *LLM as a Judge*, aplicada sobre rubrica com cinco critérios (*aderência*, *precisão factual*, *foco nas fontes*, *síntese* e *confiabilidade/alucinação*), cada um com escala de 0 a 2[8]. O script permite configurar separadamente o modelo usado como LLM juiz; nas rodadas principais analisadas, por simplificação experimental, optou-se por reutilizar o mesmo modelo nas etapas de geração e avaliação. Essa combinação entre LLM juiz e rubrica explícita é compatível com a literatura sobre avaliação automatizada de geração textual e de saídas de RAG (LIU, S. et al., 2025; LIU, Y. et al., 2023). Nas execuções principais, o modelo usado para geração e avaliação foi `gpt-5-nano`, com recuperação sobre coleção indexada no Open WebUI, e os *embeddings* `text-embedding-3-small` permaneceram registrados nos metadados dos trechos retornados.

Do ponto de vista da recuperação, o *script* de avaliação não fixa explicitamente um *top-k* nem aplica reranqueamento manual: esses passos permanecem internalizados na plataforma. Ainda assim, os artefatos da rodada base permitem observar o comportamento efetivo do sistema[9]. Nessa rodada, cada resposta retornou metadados associados a 9 a 15 trechos-fonte, com média de 12,1, distribuídos por 3 a 13 arquivos *Markdown* de origem, com média de 8,6 arquivos por resposta. Isso sugere que o contexto final utilizado na geração resultou da agregação automática de múltiplos trechos recuperados semanticamente a partir da coleção indexada.

A tipologia das perguntas não foi tomada integralmente de um único *benchmark*, mas foi inspirada por *benchmarks* recentes de avaliação de RAG, especialmente o RAGEval, que organiza consultas em famílias como pergunta factual, integração de informações, comparação numérica, sequência temporal, raciocínio em múltiplas etapas, sumarização e perguntas não respondíveis (ZHU et al., 2025). A partir dessa base, o presente experimento adaptou as categorias ao domínio parlamentar e aos riscos específicos observados no *corpus* de discursos do Senado. Assim, categorias como *factual*, *comparação*, *síntese*, *multietapas* e *evidência negativa* dialogam diretamente com a literatura recente, enquanto rótulos como *foco no autor*, *desambiguação*, *autoria cruzada*, *controle de escopo* e *estresse de recuperação* devem ser entendidos como extensões metodológicas propostas neste trabalho, criadas para tensionar problemas especialmente relevantes em consultas sobre autoria, mistura indevida de discursos, controle de escopo e robustez da

[8] Rubrica de avaliação automatizada.
[9] Análise da rodada base por pergunta.

recuperação.

5.2 Resultados alcançados

Os resultados podem ser descritos em três frentes complementares: integridade da base, inspeção manual de respostas e bateria automatizada de perguntas.

Na frente operacional, a base foi carregada e manteve-se operacional nas consultas realizadas, em coerência com os metadados gerados na preparação: 15.729 registros de entrada, 15.726 discursos aproveitados, 3 descartes por ausência de texto útil e 23.806 *chunks* persistidos para recuperação semântica. Esses números não demonstram qualidade da resposta por si só, mas indicam que o experimento partiu de uma base operacionalmente íntegra e rastreável.

Na inspeção manual, adotaram-se três estudos de caso exemplificativos, documentados no relatório público de resultados manuais[10], escolhidos para representar um caso forte, um caso de cautela e um caso de limite. No primeiro, a resposta sobre os argumentos de Paulo Paim contra a capitalização da Previdência mostrou desempenho verificável consistente: o sistema recuperou múltiplos discursos do senador, sintetizou os principais pontos e apresentou referências explícitas ao final. No segundo, diante de uma pergunta de desambiguação de autoria sobre Confúcio Moura, o sistema adotou postura cautelosa, reconhecendo insuficiência de contexto e evitando atribuições indevidas. No terceiro, diante de uma pergunta multifocal que exigia reconstrução de um plano legislativo consolidado para reduzir desigualdade, o sistema preservou parte dessa cautela, mas já operou em nível de abstração mais alto, revelando o limite do fluxo quando a consulta exige consolidação ampla, articulação entre autores e fechamento programático a partir de evidências fragmentárias.

A avaliação automatizada foi consolidada a partir das três rodadas completas executadas após o alinhamento entre o fluxo automatizado e a configuração operacional do Open WebUI[11]. Em cada rodada, 20 perguntas foram submetidas à *knowledge base*, todas as respostas foram geradas com sucesso e, em seguida, avaliadas em uma segunda etapa de avaliação por LLM como juiz, com base na rubrica definida para o experimento. As médias observadas foram 9,15, 9,55 e 9,35 pontos em 10, resultando em média agregada de 9,35. Não houve falhas nas três execuções. No vocabulário da rubrica adotada, 17 respostas da primeira rodada ficaram na faixa "pronta para uso" (8–10) e 3 na faixa "utilizável com supervisão" (5–7); nas duas rodadas seguintes, 19 respostas ficaram na primeira faixa e 1 na segunda. Essas faixas indicam qualidade estimada no escopo do experimento, e não prontidão operacional ampla. O conjunto de 20 perguntas, suas categorias e as notas obtidas nas três rodadas está disponível nos artefatos públicos da avaliação[12]. Esse material já distingue categorias inspiradas diretamente na literatura de *benchmarks* RAG (ZHU et al., 2025) e categorias introduzidas como adaptação metodológica deste trabalho.

[10] Relatório público de resultados manuais.
[11] CSV da rodada base; CSV da segunda rodada; CSV da terceira rodada; síntese de estabilidade.
[12] Conjunto de perguntas; análise por pergunta da rodada base.

Tabela 1: Síntese entre objetivos, evidências e interpretação dos resultados

Objetivo avaliado	**Evidência empírica**	**Interpretação**
Construir base verificável	15.726 discursos aproveitados, 23.806 chunks gerados e metadados legislativos preservados	A base construída mostrou-se operacional e rastreável para a avaliação realizada.
Validar consulta assistida	Três estudos de caso manuais representando caso forte, caso de cautela e caso de limite	O sistema apresenta melhor desempenho quando a pergunta é delimitada por autor, tema ou evidência documental.
Avaliar desempenho automatizado	Três rodadas completas, com médias 9,15, 9,55 e 9,35, sem falhas operacionais	O desempenho agregado foi alto nas métricas adotadas, embora com variação em itens mais complexos.
Identificar limites de uso	Oscilação em perguntas de precisão numérica, controle de escopo, multietapas e autoria cruzada	Consultas de maior abstração exigem supervisão humana e formulação cuidadosa.
Verificar robustez da avaliação por LLM	Análise manual amostral com convergência geral, mas divergência relevante em item de checagem de alucinação	O LLM como juiz é útil para escalar a avaliação, mas não substitui validação humana em casos críticos.

Rodadas complementares com outro modelo na etapa de avaliação por LLM foram usadas apenas como teste. Embora tenham completado a bateria, elas atribuíram nota máxima a todos os itens, o que sugeriu um padrão excessivamente permissivo de julgamento por parte do LLM juiz alternativo. Por essa razão, tais execuções não foram adotadas como evidência quantitativa principal, mas como alerta metodológico sobre a influência do modelo avaliador na estratégia de *LLM as a Judge*.

Os resultados por família de perguntas e por tipo de exigência cognitiva ajudam a qualificar melhor o comportamento do sistema, embora esta bateria ainda seja pequena para caracterizar de modo estável todas as categorias consideradas. Nesta amostra de 20 perguntas, consultas das categorias *factual*, *proposta*, *foco no autor*, *desambiguação* e *evidência negativa* mantiveram desempenho alto e pouca variação entre as rodadas, o que sugere boa aderência ao contexto quando a tarefa exigia localizar autoria, sintetizar argumentos delimitados ou reconhecer ausência de evidência suficiente. Em contrapartida, as perguntas que mais tensionaram o sistema foram aquelas que exigiam precisão numérica, controle de escopo, reconstrução multietapas, comparação entre autores e distinção fina entre formulações semelhantes. A maior variação ocorreu na pergunta `q15`[13], voltada à recuperação de informação numérica específica, cujas notas foram 6, 10 e 10; também apresentaram oscilação relevante a `q16`, que tensionava controle de escopo, com notas 7, 9 e 10, e a `q18`, formulada para testar autoria cruzada, com notas 8, 7 e 9. Esses casos sugerem que parte da instabilidade não decorre de falha operacional, mas da dificuldade intrínseca de avaliar respostas que combinam múltiplas fontes, números dispersos, inferências de autoria e limites de extrapolação.

Esses achados convergem com a avaliação qualitativa do projeto: perguntas mais delimitadas, ancoradas em um autor, tema ou argumento específico, tendem a produzir respostas mais fortes e verificáveis; perguntas amplas, multifocais ou formuladas de modo a induzir generalização

[13] Conjunto público de perguntas da bateria automatizada.

aumentam o risco de mistura indevida de discursos, atribuições excessivas e perda de precisão factual. A análise manual amostral da rodada base, conduzida sobre sete respostas selecionadas, indicou convergência com o LLM juiz na maior parte dos casos, mas também revelou uma divergência importante em pergunta de checagem de alucinação, na qual a avaliação humana considerou a resposta inadequada por erro de escopo apesar da nota máxima atribuída automaticamente. Essa triangulação reforça que a avaliação por LLM como juiz é útil para escalar a análise, mas deve ser interpretada como instrumento auxiliar, especialmente em tarefas abertas ou metavaliativas. Em termos metodológicos, isso sugere que a utilidade da prova de conceito é mais clara para consulta assistida e exploração do acervo com apoio documental, mas que respostas de maior abstração ainda dependem de supervisão humana e de refinamentos adicionais no desenho de recuperação, no controle de escopo e na formulação do prompt (GAO et al., 2023; WANG et al., 2025; SAAD-FALCON et al., 2024).

A inclusão de referências documentais ao longo da resposta e ao seu final mostrou-se viável por meio de instruções adequadas no *prompt*, o que facilita a conferência posterior das informações. Em síntese, os resultados sustentam a viabilidade técnica inicial da prova de conceito e oferecem evidência mais concreta de onde o sistema apresenta utilidade e onde seus limites permanecem mais visíveis. Para tornar a demonstração menos abstrata, os exemplos completos de interação manual estão disponíveis em relatório público do projeto[14], incluindo um caso de bom desempenho, um caso em que o sistema reconhece insuficiência de contexto e evita atribuições indevidas de autoria, e um caso mais desafiador em que a pergunta exige consolidação legislativa ampla sob forte restrição de contexto.

5.3 Ameaças à validade

Os resultados devem ser interpretados como evidência inicial de uma prova de conceito reprodutível, e não como *benchmark* definitivo para sistemas RAG legislativos. A principal ameaça à validade interna decorre do tamanho reduzido da bateria automatizada, composta por 20 perguntas, e do balanceamento desigual entre categorias: algumas famílias aparecem com poucos exemplos, o que limita inferências estáveis por tipo de pergunta. Há também ameaça associada ao uso de *LLM as a Judge*, pois os testes de sensibilidade indicaram que a pontuação pode variar de forma relevante conforme o modelo avaliador e a rubrica utilizada. A validade de construto é limitada pelo fato de a avaliação combinar notas automatizadas, inspeção manual e estudos de caso, sem ainda dispor de validação humana ampla e independente. Por fim, a validade externa deve ser considerada com cautela, pois os resultados dependem da configuração específica do Open WebUI, do *prompt* operacional, dos parâmetros de *chunking*, da coleção indexada e do corpus de discursos da 56ª Legislatura. Assim, os achados são mais bem compreendidos como demonstração reprodutível de viabilidade e limites em um domínio parlamentar específico, passível de replicação e expansão em estudos posteriores.

5.4 Potencial de generalização

Embora o experimento tenha sido desenhado para discursos da 56ª Legislatura do Senado Federal, parte do pipeline tende a ser reaproveitável em outros acervos legislativos. São potencialmente transferíveis a preparação documental em lotes, o enriquecimento dos *chunks* com

[14] Relatório público de resultados manuais.

metadados, a ingestão em base vetorial, o uso de *prompt* orientado a evidências, o registro de artefatos de execução e a avaliação por LLM como juiz combinada à análise manual amostral. Por outro lado, permanecem específicos do *corpus* analisado a estrutura dos campos de origem, os metadados disponíveis, a natureza dos pronunciamentos em plenário, a distribuição temporal dos discursos e a tipologia de perguntas construída para tensionar problemas de autoria, escopo e recuperação nesse domínio. Assim, a contribuição mais generalizável do trabalho não é um conjunto universal de resultados, mas um protocolo reprodutível e adaptável para construção e avaliação inicial de sistemas RAG em acervos legislativos.

5.5 Impacto na administração pública

O impacto potencial do *chatbot* legislativo com RAG na administração pública pode ser analisado em pelo menos quatro dimensões. Em primeiro lugar, há potencial de contribuição para a transparência, na medida em que as respostas passam a ser ancoradas em discursos públicos e citáveis, facilitando a verificação por terceiros. Em segundo lugar, observa-se potencial de ganho de eficiência, uma vez que o sistema pode reduzir o tempo necessário para localizar informações relevantes em grandes acervos documentais. Em terceiro lugar, a solução pode contribuir para a memória institucional, ao facilitar a recuperação de posicionamentos anteriores, temas recorrentes e evidências documentais. Por fim, identifica-se potencial de apoio à decisão, na medida em que gabinetes e equipes técnicas podem dispor de uma camada adicional de mediação informacional para explorar o acervo legislativo de forma mais estruturada (MARTELLOTE VIOLA et al., 2025; ALMEIDA; SANTOS JÚNIOR, 2025; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023).

Por operar sobre fontes controladas e permitir referência explícita aos discursos da 56ª Legislatura, a solução é mais compatível com exigências de *accountability* do que o uso isolado de um *chatbot* generalista. Essa característica assume especial relevância em contextos públicos, nos quais a confiabilidade da informação não pode ser dissociada da governança das fontes e da possibilidade de auditoria posterior.

6 Conclusão e trabalhos futuros

6.1 Síntese das contribuições

Neste trabalho, foi desenvolvida uma prova de conceito reprodutível de *chatbot* legislativo com RAG voltada ao acervo de discursos da 56ª Legislatura do Senado Federal. A solução compreende um *pipeline* de preparação documental, uma base vetorial, uma interface de consulta e *scripts* auxiliares de ingestão, avaliação e registro dos resultados. Demonstrou-se, assim, que é possível estruturar uma base semântica consultável e responder perguntas em linguagem natural com apoio em evidências recuperadas, aproximando o uso de LLMs das exigências de atualidade, verificabilidade e controle das fontes apontadas pela literatura (GAO et al., 2023). A contribuição é, portanto, metodológica e aplicada, pois não se limita ao artefato implementado: envolve também um protocolo reprodutível, preservação de metadados legislativos e uma estratégia explícita de avaliação dos resultados.

6.2 Discussão dos resultados frente aos objetivos

À luz dos objetivos propostos, os resultados constituem evidência inicial de viabilidade. A prova de conceito atendeu aos critérios centrais definidos para indexação da base de discursos da 56ª Legislatura, recuperação de trechos relevantes, geração de respostas fundamentadas e avaliação estruturada. As três rodadas automatizadas recentes completaram a bateria de 20 perguntas sem falhas operacionais e apresentaram médias entre 9,15 e 9,55 em escala de 0 a 10. A inspeção manual e a triangulação amostral reforçaram, contudo, que a qualidade de um sistema RAG institucional depende de disciplina metodológica e de decisões arquiteturais consistentes. Estratégias de *chunking*, desenho do *prompt*, qualidade dos metadados, escolha do LLM juiz e avaliação iterativa influenciam diretamente o comportamento do *chatbot*.

Tal constatação é compatível com a literatura recente, segundo a qual RAG não deve ser entendido apenas como a conexão entre um LLM e um banco vetorial, mas como uma solução sociotécnica que exige avaliação contínua, rastreabilidade, governança e critérios explícitos de sucesso, especialmente quando utilizada em funções públicas sensíveis (GAO et al., 2023; ALMEIDA; SANTOS JÚNIOR, 2025; SAAD-FALCON et al., 2024). Nesse sentido, a principal contribuição do trabalho não reside apenas na implementação do protótipo, mas também na explicitação das escolhas técnicas, limitações práticas e condições institucionais envolvidas em sua construção.

6.3 Limitações

Entre as limitações atuais da solução, destacam-se o tamanho ainda reduzido da bateria automatizada, a necessidade de validação humana mais ampla, a ausência, nesta etapa, de filtros mais sofisticados por autor, período ou tipo de discurso diretamente integrados ao fluxo de geração, a possibilidade de respostas excessivamente amplas em consultas abertas e a dependência de serviços externos para embeddings e parte da geração. Além disso, testes com LLM juiz alternativo indicaram que a estratégia de *LLM as a Judge* é sensível ao modelo escolhido, podendo produzir avaliações excessivamente permissivas. Tais limitações dialogam com alertas da literatura acerca de riscos operacionais, vieses de dados, segmentação documental e necessidade de monitoramento contínuo em sistemas RAG (GAO et al., 2023; WANG et al., 2025; LIU, S. et al., 2025).

6.4 Trabalhos futuros

Como trabalhos futuros, recomenda-se ampliar a bateria de avaliação, balancear melhor as categorias de perguntas, comparar avaliações por LLM como juiz com validações humanas independentes e experimentar *frameworks* especializados, como RAGAS, para complementar a rubrica utilizada na avaliação por LLM. Recomenda-se, ainda, incorporar filtros estruturados por metadado na etapa de recuperação, experimentar reranqueadores mais robustos, testar diferentes estratégias de *chunking* por tipo documental e implementar pós-processamento determinístico para a seção de referências.

Além disso, a prova de conceito pode ser adaptada para outros tipos de documentos legislativos, como pareceres, projetos de lei, notas técnicas e documentos administrativos relacionados ao processo legislativo. Essa expansão exigiria reavaliar metadados, estratégias de *chunking*, categorias

de pergunta, rubrica e critérios de validação em função de cada novo acervo. Em horizonte mais avançado, um desdobramento possível consiste na evolução do sistema para cenários de geração assistida de minutas, relatórios ou discursos, desde que preservados mecanismos de verificação documental, supervisão humana obrigatória e controles institucionais adequados. Dessa forma, o presente trabalho abre caminho para agenda mais ampla de pesquisa e desenvolvimento sobre inteligência artificial generativa responsável no contexto do Parlamento brasileiro.

Referências

ALMEIDA, Patricia Gomes Rêgo de; SANTOS JÚNIOR, Carlos Denner dos. Artificial intelligence governance: Understanding how public organizations implement it. **Government Information Quarterly**, v. 42, n. 1, p. 102003, 2025. DOI: 10.1016/j.giq.2024.102003. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0740624X24000959>. Acesso em: 21 abr. 2026.

ANH-HOANG, Dang; TRAN, Vu; NGUYEN, Le-Minh. Survey and Analysis of Hallucinations in Large Language Models: Attribution to Prompting Strategies or Model Behavior. **Frontiers in Artificial Intelligence**, v. 8, 2025. DOI: 10.3389/frai.2025.1622292. Disponível em: <https://www.frontiersin.org/articles/10.3389/frai.2025.1622292/full>. Acesso em: 8 abr. 2026.

BANDEIRA, Cristina Leston; BERNARDES, Cristiane Brum. Information vs Engagement in Parliamentary Websites – A Case Study of Brazil and the UK. **Revista de Sociologia e Política**, v. 24, n. 59, p. 91–107, 2016. DOI: 10.5380/rsocp.v24i59.48709. Disponível em: <https://revistas.ufpr.br/rsp/article/view/48709>. Acesso em: 9 abr. 2026.

BHAT, Sinchana Ramakanth; RUDAT, Max; SPIEKERMANN, Jannis; FLORES-HERR, Nicolas. Rethinking Chunk Size For Long-Document Retrieval: A Multi-Dataset Analysis, 2025. DOI: 10.48550/arXiv.2505.21700. arXiv: 2505.21700. Disponível em: <https://arxiv.org/abs/2505.21700>. Acesso em: 21 abr. 2026.

BLANCO, Pedro Duarte. **Letras graúdas, letras miúdas: leitura e complexidade textual dos discursos em Plenário 2007-2024**. Brasília, fev. 2026. (Texto para Discussão, 357). Disponível em: <https://www12.senado.leg.br/publicacoes/estudos-legislativos/tipos-de-estudos/textos-para-discussao/td357>. Acesso em: 21 abr. 2026.

_____. **Plenário, Palanque, Estúdio: Discursos no Plenário do Senado Federal entre 2007 e 2024**. Brasília, dez. 2025. (Texto para Discussão, 355). Disponível em: <https://www12.senado.leg.br/publicacoes/estudos-legislativos/tipos-de-estudos/textos-para-discussao/td355>. Acesso em: 21 abr. 2026.

ES, Shahul; JAMES, Jithin; ESPINOSA-ANKE, Luis; SCHOCKAERT, Steven. **Ragas: Automated Evaluation of Retrieval Augmented Generation**. 2023. DOI: 10.48550/arXiv.2309.15217. arXiv: 2309.15217. Disponível em: <https://arxiv.org/abs/2309.15217>. Acesso em: 21 abr. 2026.

GAO, Yunfan; XIONG, Yun; GAO, Xinyu; JIA, Kangxiang; PAN, Jinliu; BI, Yuxi; DAI, Yi; SUN, Jiawei; WANG, Meng; WANG, Haofen. **Retrieval-Augmented Generation for Large Language Models: A Survey**. 2023. arXiv: 2312.10997. Disponível em: <https://arxiv.org/abs/2312.10997>. Acesso em: 9 abr. 2026.

GAO, Yunfan; XIONG, Yun; WANG, Meng; WANG, Haofen. **Modular RAG: Transforming RAG Systems into LEGO-like Reconfigurable Frameworks**. 2024. arXiv: 2407.21059. Disponível em: <https://arxiv.org/abs/2407.21059>. Acesso em: 9 abr. 2026.
GEUNIS, Lotte. **Parliamentary Monitoring Organizations: Partners in Parliamentary Oversight**. International IDEA. 2023. Disponível em: <https://www.idea.int/publications/catalogue/html/parliamentary-monitoring-organizations-partners-parliamentary>. Acesso em: 8 abr. 2026.
GUPTA, Shailja; RANJAN, Rajesh; SINGH, Surya Narayan. **A Comprehensive Survey of Retrieval-Augmented Generation (RAG): Evolution, Current Landscape and Future Directions**. 2024. arXiv: 2410.12837. Disponível em: <https://arxiv.org/abs/2410.12837>. Acesso em: 8 abr. 2026.
INTER-PARLIAMENTARY UNION. **Use Cases for AI in Parliaments**. Geneva, 2024. Disponível em: <https://www.ipu.org/file/20635/download>. Acesso em: 8 abr. 2026.
KAVČIČ, Alenka; STOJANOSKI, Martin; MAROLT, Matija. Historical Parliamentary Corpora Viewer. In: PROCEEDINGS of the IV Workshop on Creating, Analysing, and Increasing Accessibility of Parliamentary Corpora (ParlaCLARIN) @ LREC-COLING 2024. Torino, 2024. Disponível em: <https://aclanthology.org/2024.parlaclarin-1.19/>. Acesso em: 9 abr. 2026.
KHALIQ, Mohammed Abdul; CHANG, Paul Yu-Chun; MA, Mingyang; PFLUGFELDER, Bernhard; MILETIĆ, Filip. RAGAR, Your Falsehood Radar: RAG-Augmented Reasoning for Political Fact-Checking Using Multimodal Large Language Models. In: PROCEEDINGS of the Seventh Fact Extraction and VERification Workshop (FEVER). Miami, Florida, USA: Association for Computational Linguistics, 2024. P. 280–296. DOI: 10.18653/v1/2024.fever-1.29. Disponível em: <https://aclanthology.org/2024.fever-1.29/>. Acesso em: 9 abr. 2026.
LIU, Shuliang; LI, Xinze; LIU, Zhenghao; YAN, Yukun; YANG, Cheng; ZENG, Zheni; LIU, Zhiyuan; SUN, Maosong; YU, Ge. Judge as A Judge: Improving the Evaluation of Retrieval-Augmented Generation through the Judge-Consistency of Large Language Models. In: FINDINGS of the Association for Computational Linguistics: ACL 2025. Vienna, Austria: Association for Computational Linguistics, 2025. P. 5788–5807. DOI: 10.18653/v1/2025.findings-acl.301. Disponível em: <https://aclanthology.org/2025.findings-acl.301/>. Acesso em: 14 abr. 2026.
LIU, Yang; ITER, Dan; XU, Yichong; WANG, Shuohang; XU, Ruochen; ZHU, Chenguang. G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. In: PROCEEDINGS of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023. P. 2511–2522. DOI: 10.18653/v1/2023.emnlp-main.153. Disponível em: <https://aclanthology.org/2023.emnlp-main.153/>. Acesso em: 14 abr. 2026.
MAHARJAN, Anuj; YADAV, Umesh. **Chunking, Retrieval, and Re-Ranking: An Empirical Evaluation of RAG Architectures for Policy Document Question Answering**. 2026. arXiv: 2601.15457. Disponível em: <https://arxiv.org/abs/2601.15457>. Acesso em: 9 abr. 2026.
MARTELLOTE VIOLA, Carla Maria; MARQUES FELIPE, Carla Beatriz; FARIAS SALES MARQUES, Luana. Inteligência Artificial na Organização do Conhecimento

do Parlamento brasileiro: um estudo aplicado aos dados e às informações legislativas. **ISKO Brasil**, n. 8, 2025. Disponível em: <https://isko.org.br/ojs/index.php/iskobrasil/article/view/52>. Acesso em: 9 abr. 2026.

MINAEE, Shervin; MIKOLOV, Tomas; NIKZAD, Narjes; CHENAGHLU, Meysam; SOCHER, Richard; AMATRIAIN, Xavier; GAO, Jianfeng. **Large Language Models: A Survey**. 2024. arXiv: 2402.06196. Disponível em: <https://arxiv.org/abs/2402.06196>. Acesso em: 8 abr. 2026.

NIE, Zhijie; FENG, Zhangchi; LI, Mingxin; ZHANG, Cunwang; ZHANG, Yanzhao; LONG, Dingkun; ZHANG, Richong. **When Text Embedding Meets Large Language Model: A Comprehensive Survey**. 2024. arXiv: 2412.09165. Disponível em: <https://arxiv.org/abs/2412.09165>. Acesso em: 8 abr. 2026.

SAAD-FALCON, Jon; KHATTAB, Omar; POTTS, Christopher; ZAHARIA, Matei. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. In: PROCEEDINGS of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Mexico City, Mexico: Association for Computational Linguistics, 2024. P. 338–354. DOI: 10.18653/v1/2024.naacl-long.20. Disponível em: <https://aclanthology.org/2024.naacl-long.20/>. Acesso em: 21 abr. 2026.

SKUBIC, Jure; FIŠER, Darja. Parliamentary Discourse Research in Political Science: Literature Review. In: PROCEEDINGS of the IV Workshop on Creating, Analysing, and Increasing Accessibility of Parliamentary Corpora (ParlaCLARIN) @ LREC-COLING. Torino, Italia, 2024. Disponível em: <https://aclanthology.org/2024.parlaclarin-1.1/>. Acesso em: 8 abr. 2026.

UNITED NATIONS. **Responsive and Accountable Public Governance**. New York, 2015. Disponível em: <https://desapublications.un.org/file/663/download>. Acesso em: 8 abr. 2026.

VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; USZKOREIT, Jakob; JONES, Llion; GOMEZ, Aidan N.; KAISER, Lukasz; POLOSUKHIN, Illia. **Attention Is All You Need**. 2017. arXiv: 1706.03762. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 8 abr. 2026.

WANG, Zhitong; GAO, Cheng; XIAO, Chaojun; HUANG, Yufei; SI, Shuzheng; LUO, Kangyang; BAI, Yuzhuo; LI, Wenhao; DUAN, Tangjian; LV, Chuancheng; LU, Guoshan; CHEN, Gang; QI, Fanchao; SUN, Maosong. Document Segmentation Matters for Retrieval-Augmented Generation. In: FINDINGS of the Association for Computational Linguistics: ACL 2025. Vienna, Austria: Association for Computational Linguistics, 2025. P. 8063–8075. DOI: 10.18653/v1/2025.findings-acl.422. Disponível em: <https://aclanthology.org/2025.findings-acl.422/>. Acesso em: 21 abr. 2026.

WESTMINSTER FOUNDATION FOR DEMOCRACY. **Guidelines for AI in Parliaments**. London, 2023. Disponível em: <https://www.agora-parl.org/sites/default/files/agora-documents/English%20-%20WFD%20AI%20Guidelines%20for%20Parliaments.pdf>. Acesso em: 8 abr. 2026.

ZHU, Kunlun; LUO, Yifan; XU, Dingling; YAN, Yukun; LIU, Zhenghao; YU, Shi; WANG, Ruobing; WANG, Shuo; LI, Yishan; ZHANG, Nan; HAN, Xu; LIU, Zhiyuan; SUN, Maosong. RAGEval: Scenario Specific RAG Evaluation Dataset Generation Framework.

In: PROCEEDINGS of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vienna, Austria: Association for Computational Linguistics, 2025. P. 8520–8544. DOI: 10.18653/v1/2025.acl-long.418. Disponível em: <https://aclanthology.org/2025.acl-long.418/>. Acesso em: 14 abr. 2026.